

La autodegeneración de la calidad de la información de la IA

Basado teoría de Shannon

Zaira Forero Santiago Forero Esteban García

Departamento de Matemáticas

Ciencias de la Computación



Contents

- 1 Introduction
- 2 Planteamiento del problema
- 3 Supuestos
- 4 Prerequisitos matemáticos y modelación
- 5 Solución e implementación
- 6 Resultados y análisis
- 7 Conclusion

Introduction

Introduction

Motivación



El contenido generado por IA se está volviendo parte del **ecosistema de datos**.



Si modelos futuros consumen contenido generado por modelos previos, puede aparecer una **pérdida progresiva de información útil**.




Este fenómeno se conoce como **model collapse**.

Nuestro enfoque:



Interpretarlo desde teoría de la información, como una **degradación acumulativa** de la calidad informacional.



Planteamiento del problema

Planteamiento del problema

EXPLICACIÓN DEL PROBLEMA

1 CONTEXTO

El crecimiento acelerado del contenido generado por modelos de IA plantea un desafío emergente: los modelos de nueva generación pueden ser entrenados, parcial o predominantemente, sobre contenido previamente generado por otros modelos.



Este proceso de autoalimentación sintética puede inducir una degradación progresiva de la calidad del contenido generado, fenómeno conocido como **model collapse** [1].

2 ESCENARIOS REALES

En cada iteración, el conjunto de datos disponible incluye una mezcla heterogénea de:



Contenido generado por humanos (alto en información original).



Contenido generado por múltiples modelos de IA, cada uno con características, calidades e inductivas distintas.



Contenido humano modificado o transformado por usuarios.



Contenido sintético sometido a procesos de curaduría o filtrado.

3 PREGUNTA CENTRAL



¿Cómo evoluciona la calidad de un conjunto de entrenamiento cuando este se construye a partir de una mezcla variable de datos humanos y contenido sintético producido por múltiples modelos de IA que interactúan entre sí?



OBJETIVO DEL TRABAJO

Formular un **modelo matemático** para describir la **dinámica de la calidad** del conjunto de entrenamiento construido a partir de la mezcla anterior, analizar la existencia de **estados estacionarios**, estudiar condiciones bajo las cuales se produce **autodegeneración** y caracterizar el efecto de la **interacción entre múltiples modelos**, tomando como punto de referencia conceptual los resultados presentados en [1].

CONCEPTOS CLAVE



Autoalimentación sintética

El entrenamiento sobre datos sintéticos previos puede retroalimentar y degradar la calidad.



Degradación progresiva

La calidad puede disminuir iteración tras iteración (model collapse).



Interacción entre múltiples modelos

La diversidad de modelos y sus interacciones afectan la evolución de la calidad.



Curaduría y filtrado

Los procesos de selección y filtrado pueden mitigar o acelerar la degradación.



Análisis matemático

Permite identificar condiciones de equilibrio, colapso o estabilización de la calidad.



Referencia conceptual: Este trabajo se basa en los resultados presentados en [1] sobre model collapse.

Supuestos

Supuestos del modelo conceptual

SUPUESTOS DEL MODELO

Para estudiar la dinámica de la calidad del contenido disponible para entrenamiento, consideramos los siguientes supuestos, inspirados conceptualmente en *model collapse* [1] y basados en ideas de la *teoría de la información de Shannon*.

S1 Variable de calidad

La calidad del conjunto de entrenamiento en la iteración t se modela mediante una cantidad escalar $I_t \in [0, 1]$, interpretada como información útil o información relevante en sentido Shannoniano.

Se normaliza la calidad del contenido humano a $I_{\text{hum}} = 1$.



S2 Mezcla de datos

En cada iteración, el conjunto de entrenamiento se forma mediante una mezcla de:

Datos humanos
(fracción h)



Datos sintéticos
(fracción $1-h$)



S3 Interacción con múltiples modelos


Existen K modelos de IA, $M_1, \dots, M_K$, cuyos contenidos combinados representan la fracción sintética total.



En esta primera formulación, se modela la calidad sintética de manera agregada mediante la variable I_t . Extensiones vectoriales pueden considerarse posteriormente.

S4 Pérdida de información por realimentación

El contenido sintético derivado del conjunto de entrenamiento de la iteración previa sufre una pérdida multiplicativa de información modelada por un parámetro $\alpha \in [0, 1]$.



Valores menores de 1 representan degradación por reciclaje iterativo (*model collapse*).

Dinámica conceptual de calidad

S5 Filtrado o curaduría parcial

Una fracción $f \in [0, 1]$ del contenido sintético es reemplazada o corregida mediante un proceso de filtrado/curaduría, contribuyendo información equivalente a la humana.



S6 Modelo recursivo de calidad

Bajo estos supuestos, la evolución temporal de la información útil del conjunto de entrenamiento está dada por la recurrencia:

$$I_{t+1} = h + (1 - h)(1 - f) \alpha I_t + f + \varepsilon_t,$$


donde ε_t representa ruido de muestreo de media cero.

- h : fracción de datos humanos nuevos.
- f : fracción filtrada/curada del contenido sintético.
- α : factor de pérdida de información por reciclaje.
- ε_t : ruido de muestreo (media cero).

S7 Interpretación del colapso

Decimos que ocurre autodegeneración o colapso cuando I_t tiende a 0 o cuando I_t converge a un punto fijo degenerado $I^* \ll 1$, lo que indica pérdida sostenida de información respecto a los datos humanos originales.

Escenarios posibles de evolución de I_t



Punto fijo I^* en el caso determinista ($\varepsilon_t = 0$)

La recurrencia tiene un punto fijo:

$$I^* = \frac{h + (1 - h)f}{1 - (1 - h)(1 - f)\alpha}$$

Si $I^* \ll 1$ (por h y f pequeños y/o α cercano a 1), el sistema converge a baja calidad: colapso.



Para evitar el colapso: aumentar h (más datos humanos), aumentar f (mejor filtrado) o reducir α (menor pérdida por reciclaje).

Prerequisitos matemáticos y modelación

Modelo conceptual de degradación

MAPA GENERAL DEL MODELO

¿Cómo evoluciona la calidad del entrenamiento cuando se recicla contenido sintético generado por múltiples modelos de IA?

FASES DEL DESARROLLO DEL MODELO

1 REQUISITOS Y MECANISMOS DEL COLAPSO

Identificamos las condiciones necesarias para que ocurra la autodegeneración (model collapse).

MECANISMOS CLAVE



C1 Realimentación recursiva: las salidas se usan como datos de la siguiente iteración.



C2 Insuficiente aporte humano: poca nueva información humana por iteración.



C3 Pérdida acumulativa de información: cada reuso introduce degradación (ruido, sesgo, compresión).



C4 Filtrado débil o inexistente: la curaduría no reemplaza suficiente contenido de baja calidad.



C5 Compatibilidad entre modelos: la realimentación entre modelos puede amplificar la degeneración.



2 TEORÍA DE LA INFORMACIÓN (SHANNON)

Usamos conceptos de la teoría de la información como marco intuitivo y cuantificable.



Entropía (Shannon)

$$H(X) = - \sum_x P(x) \log_2 P(x)$$

Mide la incertidumbre promedio de una variable aleatoria X (en bits).



Divergencia KL (intuición)

$$D_{KL}(P||Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}$$

Pérdida de información (en bits) al aproximar P con Q .



Medida de calidad informacional I

$$I \approx 1 - \kappa \cdot D_{KL}(P||Q)$$

$I \in [0, 1]$ cuantifica la información útil respecto a la distribución real P .
Mayor $I \rightarrow$ mejor calidad.



3 MODELO COMBINADO

Proponemos un modelo que combina las ideas de model collapse y la interpretación informacional.

Datos humanos



Datos sintéticos



Entrenamiento con mezcla variable y filtrado



Modelo reentrenado

Parametros modelo

MODELO RECURSIVO (DINÁMICA DE LA CALIDAD)

VARIABLE PRINCIPAL



$$I_t \in [0, 1]$$

información útil (calidad)
del conjunto de entrenamiento
en la iteración t .

ECUACIÓN DE RECURRENCIA (DETERMINISTA)

$$I_{t+1} = h + (1-h) [(1-f) \alpha I_t + f]$$

INTERPRETACIÓN



aporte humano nuevo
(información = 1)



$(1-h)(1-f) \alpha I_t$
sintético no filtrado
(degradado por α)



$(1-h)f$
sintético filtrado/reemplazado
por humano (información = 1)

PARÁMETROS

h : fracción de contenido humano nuevo por iteración.
 f : eficacia de filtrado/curaduría (reemplaza por humano).
 α : factor de degradación por realimentación recursiva
(0 = pérdida total, 1 = sin pérdida).
 ϵ_t : ruido de muestreo (opcional, $E[\epsilon_t] = 0$).

PUNTOS FIJOS Y ESTABILIDAD

Punto fijo I^* (estado estacionario) satisface:

$$I^* = h + (1-h)(1-f) \alpha I^* + (1-h)f$$

Resolviendo:

$$I^* = \frac{h + (1-h)f}{1 - (1-h)(1-f)\alpha}$$

Condición de estabilidad local:

$$\lambda = (1-h)(1-f)\alpha$$

El sistema es estable si $|\lambda| < 1$.
Las iteraciones convergen
linealmente a I^* .



VELOCIDAD DE CONVERGENCIA

Solución explícita (sin ruido):

$$I_t = I^* + (I_0 - I^*) \lambda^t$$

donde $\lambda = (1-h)(1-f)\alpha$.

Si $0 < |\lambda| < 1$: convergencia
exponencial a I^* .

Si $|\lambda| \approx 1$: convergencia lenta.

Si $|\lambda| > 1$: inestabilidad
o divergencia.



EXTENSIÓN A MÚLTIPLES MODELOS


Modelo vectorial

Para K modelos, definimos $I_t = (I_t^{(1)}, \dots, I_t^{(K)})^T$.

$$I_{t+1} = h + (1-h) \odot [(1-f) \odot (A, W I_t) + f]$$

Donde:

- $h, f \in [0, 1]^K$: vectores de fracción humana y filtrado por modelo.
- A : matriz diagonal con α_i (degradación por modelo).
- $W \in \mathbb{R}^{K \times K}$: matriz de mezcla (qué modelo j alimenta al modelo i).
- $\odot$: producto elemento a elemento.



Estabilidad (intuición)

En la versión lineal y homogénea (parámetros
iguales por modelo):

$$(1-h)(1-f) \rho(A, W) < 1$$

donde $\rho(A, W)$ es el radio espectral
(máximo autovalor en valor absoluto)
de A, W .



INTUICIÓN


Redes de interacción
con realimentación
fuerte (autovalores
grandes) aumentan
el riesgo de colapso.



Limitación experimental

Experimento ideal

El experimento ideal para estudiar el *model collapse* es un ciclo **multi-generación** controlado.



Pero...

Pero esto requiere alto costo computacional:



fine-tuning



múltiples modelos



datasets grandes



mucho tiempo de GPU

Teoría de Shannon aplicada al experimento



En lugar de medir “calidad” de manera subjetiva, usamos una **fente discreta controlada**.



Fuente:

$$X \in \{0, 1, \dots, 15\}$$



Como hay 16 símbolos equiprobables:

$$H(X) = \log_2(16) = 4 \text{ bits}$$



Después de t retransmisiones del LLM recuperamos $\hat{X}_t$.

La información preservada se mide con:

$$I(X; \hat{X}_t)$$



$$q_t = \frac{I(X; \hat{X}_t)}{H(X)}$$

q_t representa la **fracción de información original recuperable**.

Codificación del mensaje



Comparamos dos formas de transmitir los **4 bits**:



Uncoded

- ✓ envía los 4 bits directamente;
- ✓ tasa = 1;
- ✓ no tiene redundancia.

1 0 1 1



Hamming(7,4)

- ✓ codifica 4 bits en 7 bits;
- ✓ agrega bits de paridad;
- ✓ puede corregir ciertos errores o *erasures*.

1 0 1 1

4 bits de información



1 0 1 1 0 1 1

7 bits transmitidos

bits de paridad

Esquema	Longitud	Tasa	Redundancia
Uncoded	4	1	No
Hamming(7,4)	7	4/7	Sí



Pregunta: ¿la redundancia ayuda a preservar información después de varias retransmisiones?

Solución e implementación

Idea inicial: model collapse por reentrenamiento

IDEA DE SOLUCIÓN

Metodología iterativa para analizar la autodegeneración de la información



Experimento implementado



Modelo usado:
SmoLM2-360M-Instruct



Eventos:
9216



Hops:
5



Repeticiones:
32 por símbolo



Fuente:
16 símbolos

Resultados y análisis

Resultado principal

Condición	BLER en hop 5
 Uncoded + raw	0.2539
 Hamming(7,4) + raw	0.1621



Diferencia:

$$\Delta = \text{BLER}(\text{Hamming}) - \text{BLER}(\text{Uncoded})$$

$$\Delta = -0.0918$$

$$\text{IC } 95\% = [-0.1406, -0.0430]$$

$$p \text{ McNemar} = 0.0004369$$



Hamming(7,4) redujo el error de bloque en
≈ 9.18 puntos porcentuales.

Análisis del resultado

1



La **redundancia de Hamming** ayudó a recuperar mensajes cuando el LLM omitía o deformaba relaciones.

2



La mayoría de fallos fueron **erasures**, no bits incorrectos.

3



Raw funcionó mejor que **canonical**:


- **raw** conserva información textual residual;
- **canonical** convierte una falla de parseo en erasure absorbente.

4



El resultado muestra el **tradeoff clásico**: menor tasa, mayor confiabilidad.

Evidencia principal (modo raw, hop 5)



Tradeoff clásico: tasa vs. confiabilidad

Mayor tasa
(menos redundancia)



Mayor error
(menor confiabilidad)



Menor tasa
(más redundancia)



Menor error
(mayor confiabilidad)

Conclusion

Conclusion

- 

El modelo conceptual describe la **autogeneración** como pérdida de información útil.
- 

Por **costo computacional**, no entrenamos modelos recursivamente.
- 

Implementamos un **experimento alternativo**: un LLM fijo como canal ruidoso de Shannon.
- 

Con una **fuentes de 4 bits**, medimos información recuperada después de 5 hops.
- 

Hamming(7,4) redujo significativamente el error frente a uncoded.



La teoría de codificación sí aporta herramientas para preservar información en cascadas de LLMs.

Thank you!