

Autodegeneración de la Calidad de la Información en IA: Un Modelo Basado en la Teoría de Shannon con Validación Empírica en Cruces de Modelos de Lenguaje

Santiago Forero Rosales, Zaira Alejandra Forero Rojas, Esteban García Gaitán

Departamento de Ciencias de la Computación · Universidad Nacional de Colombia

{sanforeroro, zforeror, esgarciag}@unal.edu.co

Resumen—Se presenta un modelo matemático para el fenómeno de autodegeneración —conocido como *model collapse*— en sistemas de generación de contenido por inteligencia artificial, formulado en el marco de la teoría de la información de Shannon. La calidad del corpus de entrenamiento en la iteración t se representa mediante un escalar $I_t \in [0, 1]$ de información útil respecto a la distribución humana de referencia. Se derivan puntos fijos en forma cerrada, condiciones explícitas de estabilidad y una extensión multi-modelo mediante una matriz de mezcla $\mathbf{W}$ cuyo radio espectral $\rho(\mathbf{W})$ determina la estabilidad colectiva. Adicionalmente, se presenta una extensión empírica que mide el factor de degradación α de forma directa sobre cuatro modelos de lenguaje de código abierto (pythia-70 M, DistilGPT-2, SmolLM2-135 M y Qwen2.5-0.5B), utilizando el corpus SQuAD como referencia humana. Los resultados numéricos y empíricos convergen en las mismas conclusiones de uso: mantener una inyección mínima de datos humanos, activar la curaduría de forma anticipada y diseñar arquitecturas de mezcla que minimicen la realimentación circular.

Palabras clave—*model collapse*, teoría de la información, entropía de Shannon, reentrenamiento recursivo, datos sintéticos, cross-entropy, modelos de lenguaje.

I. INTRODUCCIÓN

La proliferación de modelos generativos de inteligencia artificial ha convertido el contenido sintético en una fracción creciente de los datos disponibles en plataformas digitales. Con ello, los modelos de próxima generación se entrenan en proporciones cada vez mayores sobre salidas de sus predecesores, un proceso de autoalimentación que Shumailov et al. [1] identificaron como causa de una degradación progresiva e irreversible de la calidad: el denominado *model collapse*.

El análisis original [1] se apoya en divergencias distribucionales y errores de estimación estadística. Este trabajo propone una perspectiva complementaria, enraizada en la teoría de la información de Shannon [2]: la calidad del corpus de entrenamiento se modela como una medida escalar $I_t \in [0, 1]$ de información útil respecto a la distribución humana original. Cada ciclo de reciclaje actúa como una compresión con pérdida que disipa información, a menos que una inyección suficiente de datos humanos o una curaduría de alta calidad la repongan.

Sobre esta base teórica se construye además una extensión empírica: en lugar de tratar α como parámetro libre, se mide directamente sobre modelos reales a través de la cross-entropy cruzada entre generadores y evaluadores, cuantificando la asimetría inherente de los cruces y validando con datos reales las predicciones del modelo.

II. PLANTEAMIENTO DEL PROBLEMA

El corpus disponible en cada iteración de entrenamiento es una mezcla heterogénea de contenido original humano, salidas de uno o más modelos de IA con distintos perfiles de calidad, contenido editado por humanos y contenido sintético sometido a curaduría. La pregunta central es:

¿Cómo evoluciona la calidad de un corpus de entrenamiento construido a partir de una mezcla variable de datos humanos y contenido sintético producido por múltiples modelos de IA en interacción?

Se buscan puntos fijos de esta dinámica, condiciones para el colapso y la influencia de la estructura de interacción entre modelos.

III. SUPUESTOS DEL MODELO

S1 — Variable de calidad. La calidad del corpus en la iteración t es un escalar $I_t \in [0, 1]$. El contenido humano tiene calidad $I_{\text{hum}} = 1$.

S2 — Mezcla de datos. El corpus combina una fracción h de datos humanos y $(1 - h)$ de datos sintéticos.

S3 — Pérdida multiplicativa. El contenido sintético sufre una pérdida de información codificada por $\alpha \in [0, 1]$ por cada ciclo de reúso.

S4 — Curaduría. Una fracción $f \in [0, 1]$ del contenido sintético se reemplaza mediante filtrado, aportando información equivalente a la humana.

S5 — Recurrencia. La dinámica discreta de calidad es:

$$I_{t+1} = h + (1-h)[(1-f)\alpha I_t + f] + \varepsilon_t, \quad (1)$$

donde ε_t es ruido de muestreo de media cero ($\varepsilon_t \equiv 0$ en la versión determinista).

S6 — Colapso. El colapso ocurre cuando $I_t \rightarrow 0$ o converge a un punto fijo degenerado $I^* \ll 1$.

IV. DESARROLLO MATEMÁTICO

A. Marco Shannoniano

La entropía de Shannon $H(X) = -\sum_x P(x) \log_2 P(x)$ cuantifica la incertidumbre media de una distribución. La divergencia de Kullback–Leibler $D_{\text{KL}}(P||Q)$ mide la pérdida de información al aproximar la distribución real P con Q . Operacionalmente, $I_t \approx 1 - \kappa \cdot D_{\text{KL}}(P||Q_t)$: cuando el corpus efectivo Q_t se aleja de P , I_t decrece. La recurrencia (1) codifica esta degradación sin necesidad de calcular D_{KL} explícitamente.

B. Puntos Fijos y Estabilidad

Imponiendo $I_{t+1} = I_t = I^*$ en (1) sin ruido:

$$I^* = \frac{h + (1-h)f}{1 - (1-h)(1-f)\alpha}. \quad (2)$$

La función de iteración $F(I) = h + (1-h)[(1-f)\alpha I + f]$ es afín con derivada

$$\lambda := (1-h)(1-f)\alpha. \quad (3)$$

El punto fijo es localmente estable si y solo si $|\lambda| < 1$, es decir:

$$(1-h)(1-f)\alpha < 1. \quad (4)$$

Un h grande (datos humanos abundantes) o un f grande (curaduría eficaz) reduce λ , garantizando convergencia. Por el contrario, $h \approx 0$, $f \approx 0$ y $\alpha \approx 1$ acerca λ a 1, induciendo convergencia lenta hacia un I^* muy bajo o divergencia.

C. Trayectoria y Tasa de Convergencia

La solución cerrada del sistema determinista es:

$$I_t = I^* + (I_0 - I^*)\lambda^t. \quad (5)$$

La convergencia es exponencial con constante de tiempo $\tau = -1/\log|\lambda|$. Cerca de $\lambda = 1$ la dinámica es lenta; para $\lambda > 1$ la trayectoria diverge del punto fijo y la saturación en $[0, 1]$ determina el atractor final.

D. Extensión Multi-Modelo

Para K modelos en interacción, sea

$$\mathbf{I}_t = (I_t^{(1)}, \dots, I_t^{(K)})^\top,$$

una generalización lineal es:

$$\mathbf{I}_{t+1} = \mathbf{h} + (1-h) \odot [(1-f) \odot (\mathbf{A}\mathbf{W}\mathbf{I}_t) + \mathbf{f}], \quad (6)$$

donde $\mathbf{A}$ es la matriz diagonal de factores de degradación y $\mathbf{W} \in \mathbb{R}^{K \times K}$ es la matriz de mezcla. En el caso homogéneo el Jacobiano es $J = (1-h)(1-f)\alpha\mathbf{W}$ y la condición de estabilidad es:

$$(1-h)(1-f)\alpha \cdot \rho(\mathbf{W}) < 1, \quad (7)$$

donde $\rho(\mathbf{W})$ es el radio espectral de $\mathbf{W}$. Una $\mathbf{W}$ con alto $\rho(\mathbf{W})$ —mezcla circular intensa— amplifica el riesgo de colapso; arquitecturas que reducen $\rho(\mathbf{W})$ mejoran la resiliencia.

V. SIMULACIONES NUMÉRICAS

Se simula (1) con parámetros dependientes del tiempo: $h_t = h_0 \exp(-\gamma t)$, $f_t = f_{\max}[1 - \exp(-\delta t)]$, $\alpha_t = \alpha_0 + \alpha_1(1 - I_t)$. Los valores de referencia son $I_0 = 1$, $h_0 = 0,2$, $f_{\max} = 0,4$, $\alpha_0 = 0,9$, con $\gamma = 0,01$, $\delta = 0,03$, $\alpha_1 = 0,1$ y $T = 300$ iteraciones.

A. Trayectoria Base

La Figura 1 muestra tres fases: descenso inicial de I_t mientras la curaduría f_t aún es baja; recuperación parcial al crecer f_t ; y meseta cuasi-estacionaria. La curaduría, aun tardía, evita el colapso completo.




Figura 1. Calidad I_t y parámetros dinámicos h_t , f_t , α_t (eje derecho).

B. Efecto de γ

La Figura 2 compara trayectorias para $\gamma \in \{0; 0,005; 0,01; 0,02\}$. Mayor γ implica agotamiento más rápido de datos humanos y convergencia a valores asintóticos de I_t notablemente más bajos.




Figura 2. Trayectorias de I_t para distintos valores de γ .

C. Efecto de δ

La Figura 3 varía $\delta \in \{0; 0,01; 0,03; 0,05\}$. Con $\delta = 0$ el filtrado permanece nulo e I_t colapsa. Una curaduría que se activa rápidamente intercepta la degradación antes de que h_t se agote.




Figura 3. Trayectorias de I_t para distintos valores de δ .

D. Diagrama de Fase

La Figura 4 sintetiza la interacción (γ, δ) mediante la calidad media final $\bar{I} = \frac{1}{20} \sum_{t=T-19}^T I_t$ ($T = 400$). Se identifican dos regiones: alta calidad (γ pequeño, δ moderado) y colapso (γ grande, δ pequeño). La frontera define condiciones de frontera que, si se sobrepasan sin aumentar δ , conducen a autodegeneración difícil de revertir.

E. Degradación Adaptativa

La Figura 5 explora $\alpha_1 \in \{0; 0,05; 0,1; 0,2\}$. La dependencia de α_t respecto a I_t introduce un comportamiento de umbral: cuando la calidad cae, la degradación se intensifica y la recuperación se vuelve más lenta, pudiendo atrapar al sistema en




Figura 4. Diagrama de fase (γ, δ) con calidad media final $\bar{I}$.

un atractor de baja calidad.




Figura 5. Trayectorias de I_t para distintos valores de α_1 .

VI. EXTENSIÓN EMPÍRICA: CRUCES ENTRE MODELOS

Los experimentos anteriores tratan α como parámetro libre. En esta sección se mide de forma empírica sobre cuatro modelos de lenguaje autorregresivos de código abierto, cuantificando la asimetría inherente de los cruces y anclando el modelo teórico en datos reales.

A. Modelos y Corpus Humano

Se emplean los modelos del Cuadro 1, elegidos por pertenecer a familias distintas y cubrir un rango de capacidad de un orden de magnitud:

Como referencia humana se utiliza el corpus SQuAD [4]: sus contextos, párrafos de Wikipedia redactados por personas, sirven tanto como semillas de generación comunes para todos los modelos (evitando ventajas temáticas) como materialización

Cuadro 1. Modelos de lenguaje empleados en el experimento de cruces.

Etiqueta	Identificador HuggingFace	Parám.
pythia70m	EleutherAI/pythia-70m	~70 M
distilgpt2	distilgpt2	~82 M
smollm2	HuggingFaceTB/SmolLM2-135M	~135 M
qwen0.5b	Qwen/Qwen2.5-0.5B	~500 M

empírica de $I_{\text{hum}} = 1$.

B. Medida Empírica de α

Dado un texto $x = (x_1, \dots, x_N)$ y un modelo M , la cross-entropy media por token es:

$$H_M(x) = -\frac{1}{N} \sum_{i=1}^N \log P_M(x_i | x_{<i}). \quad (8)$$

Esta cantidad es el análogo empírico de D_{KL} : cuanto más sorpresivo resulte x para M , mayor es la divergencia respecto a la distribución generadora. El factor de degradación del cruce $A \rightarrow B$ se define como:

$$\alpha_{A \rightarrow B} = \frac{H_A(x_A)}{H_B(x_A)}, \quad (9)$$

donde x_A es el corpus generado por A . La normalización por $H_A(x_A)$ separa la predicibilidad intrínseca del texto de A del costo adicional que paga B . Cuando B describe el texto de A casi tan bien como el propio A , $\alpha \rightarrow 1$ (mínima pérdida); cuando B lo encuentra muy sorpresivo, $\alpha \ll 1$ (pérdida intensa).

La relación es inherentemente no conmutativa: $\alpha_{A \rightarrow B} \neq \alpha_{B \rightarrow A}$, estructura que codifica exactamente la matriz $\mathbf{W}$ de la ecuación (6).

C. Protocolo

El experimento sigue tres pasos. Primero, cada modelo genera continuaciones a partir de los mismos fragmentos iniciales de SQuAD (temperatura 1,0, nucleus sampling $p = 0,95$).

Segundo, para cada par (generador i , evaluador j) se calcula $H_j(x_i)$ según (8), incluyendo la fila humana, obteniendo la matriz de degradación $\alpha_{i \rightarrow j}$ mediante (9).

Tercero, cada $\alpha_{i \rightarrow j}$ medido se inyecta en la recurrencia (1) con $h = 0,05$ y $f = 0$, obteniendo tanto la trayectoria I_t como la calidad estacionaria $I_{t \rightarrow j}^*$ mediante (2).

D. Resultados

El Cuadro 2 reporta la matriz empírica $\alpha_{i \rightarrow j}$ y la Figura 6 la visualiza junto con las calidades estacionarias:

Cuadro 2. Matriz de degradación empírica $\alpha_{i \rightarrow j}$ según (9). Diagonal fijada a 1.

Gen. \ Eval.	py70m	dgpt2	sm2	qw0.5b
pythia70m	1.000	0.858	0.885	0.980
distilgpt2	0.712	1.000	0.817	0.929
smollm2	0.612	0.688	1.000	0.937
qwen0.5b	0.474	0.514	0.599	1.000
humano	0.614	0.676	0.765	1.000




Figura 6. Matrices empíricas α (izquierda) e I^* (derecha). La asimetría fuera de la diagonal evidencia la no conmutatividad de los cruces.

Cuatro observaciones merecen atención. Primero, la fila humana del Cuadro 2 ordena los modelos de forma perfectamente monótona con la capacidad: $\alpha_{\text{hum} \rightarrow \text{qwen}} = 1,000 > \alpha_{\text{hum} \rightarrow \text{sm2}} = 0,765 > \alpha_{\text{hum} \rightarrow \text{dgpt2}} = 0,676 > \alpha_{\text{hum} \rightarrow \text{py70m}} = 0,614$; el modelo más pequeño pierde cerca del 39 % de la información humana en un único paso de procesamiento.

Segundo, los modelos de mayor capacidad son los mejores evaluadores — α entrante medio de qwen0.5b: 0,962— pero su texto es el que peor sobrevive al ser procesado por los más pequeños — α saliente medio de qwen0.5b: 0,529, el mínimo del experimento—.

Tercero, el cruce más degradante es $\text{qwen0.5b} \rightarrow \text{pythia70m}$ con $\alpha = 0,474$ e $I^* = 0,120$, reproduciendo empíricamente la condición C5 de la Sección 3.

Cuarto, pequeños cambios en α se amplifican en el estacionario: con $f = 0$ y $h = 0,05$, $I^* = h/[1 - (1 - h)\alpha]$, expresión muy sensible cerca de $\alpha \rightarrow 1$; así, la brecha $\alpha_{\text{hum} \rightarrow \text{sm2}} - \alpha_{\text{hum} \rightarrow \text{py70m}} \approx 0,15$ casi duplica la diferencia en la meseta de calidad.




Figura 7. Dinámica I_t para todos los cruces $i \rightarrow j$ ($h = 0,05$, $f = 0$). Trazo grueso: cruces con origen humano.




Figura 9. Ranking de preservación: α entrante medio (mejor evaluador) y α saliente medio (texto más sobreviviente).




Figura 8. Trayectorias I_t desagregadas por generador. Cada panel muestra la supervivencia del texto de un mismo origen según qué modelo lo evalúa.

La Figura 9 resume el ranking de preservación. qwen0.5b destaca como mejor evaluador (α entrante medio más alto) y pythia70m como el modelo cuyo texto sobrevive mejor a ser procesado por los demás (α saliente medio más alto). Este último resultado, aparentemente paradójico, se debe a que pythia70m genera texto suficientemente genérico como para que todos los evaluadores lo encuentren predecible.

E. Modelo Vectorial Acoplado

El bloque modelo–modelo de la matriz α , normalizado por filas, se emplea como matriz de mezcla $\mathbf{W}$ empírica en la dinámica acoplada (6). Al ser $\mathbf{W}$ estocástica por filas, $\rho(\mathbf{W}) = 1$ y la condición de estabilidad (7) se reduce a $(1-h)(1-f) < 1$. Con $h = 0,05$ y $f = 0$ el coeficiente vale $0,95 < 1$: el sistema es estable. La Figura 10 confirma que todas las componentes $I_t^{(k)}$ convergen a la misma meseta, con variaciones inferiores al 2 % respecto al valor inicial, en plena coherencia con la

condición analítica.




Figura 10. Dinámica vectorial acoplada con la matriz $\mathbf{W}$ empírica ($\rho(\mathbf{W}) = 1,00$, coeficiente de estabilidad = 0,95).

F. Alcance y Limitaciones

Los valores absolutos de $\alpha_{i \rightarrow j}$ dependen del conjunto de semillas, la temperatura de muestreo y la longitud de generación; lo que resulta robusto es el orden relativo y la estructura asimétrica de la matriz. Un estudio de mayor generalidad requeriría promediar sobre múltiples semillas y un corpus de referencia de mayor tamaño. La normalización de la fila humana mediante $\min_j H_j(x_{\text{hum}})$ es una convención razonable pero no única; una alternativa sería un modelo de n -gramas ajustado sobre el corpus humano.

VII. DISCUSIÓN

Umbral de datos humanos. La condición (4) fija un mínimo de h por debajo del cual el colapso es inevitable para α y f dados. Los resultados empíricos calibran este umbral:

con $\alpha \approx 0,76$ (correspondiente a smollm2 evaluando texto humano) y $f = 0$, la condición exige $h > 0,24$ para garantizar estabilidad. Esta cifra tiene interpretación directa: menos del 24 % de datos humanos en cada ronda de entrenamiento conduce a degradación.

Curaduría anticipada. El experimento de δ muestra que no basta con que exista curaduría: debe activarse antes de que h_t se vuelva despreciable. Una vez que el sistema entra en un régimen sintético dominante con f bajo, incluso valores altos de $f_{\max}$ son insuficientes para revertir el daño acumulado.

Asimetría como riesgo de red. La no conmutatividad de los cruces $\alpha_{A \rightarrow B} \neq \alpha_{B \rightarrow A}$ tiene consecuencias directas para el diseño de pipelines de datos: pares de modelos con gran asimetría (por ejemplo, qwen0.5b $\rightarrow$ pythia70m, $\alpha = 0,47$ frente a pythia70m $\rightarrow$ qwen0.5b, $\alpha = 0,98$) crean flujos de información unidireccionales que el modelo escalar no captura pero la formulación matricial (6) sí recoge.

Compatibilidad con Shumailov et al. Nuestro modelo reproduce la dinámica cualitativa de [1] y la calibra sobre modelos actuales, añadiendo criterios de política operativos que la formulación distribucional original no ofrece directamente.

VIII. CONCLUSIONES

- Se formuló una recurrencia escalar (1) que modela la dinámica de calidad del corpus bajo reentrenamiento recursivo, con tres parámetros de control interpretables: h (datos humanos), f (curaduría) y α (degradación por reúso).
- Se derivaron el punto fijo en forma cerrada (2) y la condición de estabilidad explícita (4), separando analíticamente los regímenes de calidad mantenida y de colapso.
- La extensión multi-modelo (6)–(7) identifica $\rho(\mathbf{W})$ como el parámetro topológico crítico; la validación empírica de-

muestra que, cuando $\mathbf{W}$ es estocástica por filas, la estabilidad depende exclusivamente del margen $(1-h)(1-f)$.

- La extensión empírica mide α directamente sobre modelos reales y corpus humano (SQuAD), cuantificando la no conmutatividad de los cruces y calibrando los umbrales teóricos con datos concretos.
- Las recomendaciones prácticas son: mantener $h \geq h_{\min}$ según la condición (4) calibrada empíricamente; desplegar curaduría con tasa δ proporcional a γ para evitar cruzar la frontera del diagrama de fase; y diseñar pipelines de datos con matrices de mezcla $\mathbf{W}$ que minimicen dependencias circulares entre modelos de capacidades muy dispares.

REFERENCIAS

- [1] I. Shumailov, Z. Shumaylov, Y. Zhao *et al.*, “AI models collapse when trained on recursively generated data,” *arXiv:2305.17493*, 2023.
- [2] C. E. Shannon, “A mathematical theory of communication,” *Bell System Technical Journal*, vol. 27, pp. 379–423, 1948.
- [3] S. Kullback y R. A. Leibler, “On information and sufficiency,” *Annals of Mathematical Statistics*, vol. 22, no. 1, pp. 79–86, 1951.
- [4] P. Rajpurkar, J. Zhang, K. Lopyrev, P. Liang, “SQuAD: 100,000+ Questions for Machine Comprehension of Text,” *Proc. EMNLP*, 2016.
- [5] Qwen Team, “Qwen2.5: A Party of Foundation Models,” Technical Report, 2024.
- [6] T. M. Cover y J. A. Thomas, *Elements of Information Theory*, 2nd ed. Wiley, 2006.