

La autodegeneración de la calidad de la información de la IA Basado teoría de Shannon

21 de julio de 2026

Integrante 1:	Santiago Forero Rosales
Correo:	sanforeroro@unal.edu.co
Programa:	Ciencias de la computación
Integrante 2:	Zaira Alejandra Forero Rojas
Correo:	zforeror@unal.edu.co
Programa:	Ciencias de la computación y Matemáticas
Integrante 3:	Esteban García Gaitán
Correo:	esgarciag@unal.edu.co
Programa:	Ciencias de la computación

Resumen

Este informe desarrolla un modelo matemático y un análisis cualitativo del fenómeno de *autodegeneración* o *model collapse* en sistemas de generación de contenido por inteligencia artificial. Se propone un modelo discreto compacto para la calidad del contenido disponible en cada iteración, se extiende a múltiples modelos con interacción, se analizan puntos fijos y condiciones de colapso, y se proponen experimentos numéricos para estudiar patrones a largo plazo. El desarrollo está inspirado en Shumailov e.

Índice

1. Introducción	2
2. Planteamiento del problema	3
3. Supuestos del modelo	4
4. Desarrollo del modelo matemático	4
4.1. Requisitos y mecanismos que favorecen el colapso	4
4.2. Teoría de Shannon	5
4.3. Modelo	6
4.3.1. Variables y parámetros	6
4.3.2. Análisis de puntos fijos y estabilidad (caso determinista)	6
4.3.3. Velocidad de convergencia y tasa de degradación	7
4.3.4. Extensión simple a múltiples modelos (vectorial, intuición)	7
4.4. Comentarios finales sobre el modelo	7
5. Solución e implementación	8
5.1. Puntos fijos y condiciones de equilibrio (caso escalar)	8
5.2. Estabilidad (linealización)	8
5.3. Casos no lineales y múltiples puntos fijos	8

6. Resultados y análisis (dinámica de la calidad)	9
6.1. Regímenes principales	9
6.2. Efecto de múltiples modelos	9
7. Discusión	9
8. Resultados numéricos y visualización de la dinámica	10
8.1. Trayectoria base y evolución de h_t, f_t, α_t (Figura 1)	10
8.2. Efecto de la caída de h_t variación de γ (Figura 2)	11
8.3. Efecto de la mejora de la curaduría: variación de δ (Figura 3)	12
8.4. Diagrama de fase en el plano (γ, δ) (Figura 4)	13
8.5. Degradación adaptativa y efecto de α_1 (Figura 5)	14
9. Extensión empírica: preservación de información en cruces de modelos de lenguaje	15
9.1. Modelos y corpus de referencia humano	15
9.2. Medida empírica de información: cross-entropy	16
9.3. Protocolo experimental	17
9.4. Resultados del experimento de cruces	17
9.5. Acoplamiento vectorial con la matriz empírica	20
9.6. Alcance y limitaciones	20
10. Conclusiones	21
A. Anexo: código Python para simulaciones	21
B. Anexo: sugerencias de experimentos numéricos	22
C. Anexo: código Python para simulaciones dinámicas	22

1. Introducción

El auge reciente de los modelos generativos de inteligencia artificial (IA) ha incrementado de manera significativa la cantidad de contenido sintético disponible en plataformas digitales. Debido a esta abundancia, es cada vez más probable que futuros modelos de IA sean entrenados no solo con datos humanos originales, sino también con contenido previamente generado por otros modelos. Este fenómeno ha sido estudiado formalmente en [1], donde se demuestra que el reentrenamiento recursivo sobre datos sintéticos puede inducir una degradación progresiva y acumulativa en la calidad de los modelos, fenómeno denominado *model collapse*.

En el enfoque clásico del artículo, la degradación se analiza mediante herramientas matemáticas avanzadas relacionadas con la teoría del muestreo, la estimación estadística y la divergencia entre distribuciones. Sin embargo, una interpretación alternativa —más intuitiva y más cercana a la teoría de la información de Shannon— consiste en considerar la calidad del contenido disponible en cada iteración como una medida de *información útil*. Desde esta perspectiva, el problema puede entenderse como una pérdida acumulativa de información relevante cuando el sistema depende demasiado del contenido sintético y no recibe una entrada suficiente de información humana.

Bajo esta visión informacional, la calidad del conjunto de entrenamiento en cada iteración se modela mediante una variable $I_t \in [0, 1]$, interpretada como la cantidad de información relevante respecto a los datos humanos originales. Cada vez que el contenido sintético es reutilizado para entrenar nuevos modelos, una parte de esta información se pierde, de forma análoga al efecto de una compresión con pérdida repetida. Este mecanismo captura de forma natural la intuición

central del *model collapse*: la realimentación recursiva degrada la información disponible, a menos que exista una entrada suficiente de contenido humano o mecanismos de filtrado que restauren parte de esta información.

Adicionalmente, en entornos reales no existe un único modelo de IA, sino múltiples modelos que interactúan produciendo y consumiendo datos sintéticos. El contenido humano también coopera con estos modelos mediante edición, transformación y corrección. Comprender estas interacciones requiere un modelo general que combine:

- la mezcla entre información humana y sintética,
- la pérdida de información asociada al reciclaje,
- la interacción entre múltiples modelos de IA,
- y los posibles mecanismos de curaduría o filtrado.

El objetivo de este trabajo es formular un modelo matemático sencillo, basado en ideas fundamentales de la teoría de la información, que capture de manera cualitativa el comportamiento observado en [1]. A partir de dicho modelo se analizan estados estacionarios, condiciones de colapso, efectos de la interacción entre múltiples modelos y patrones a largo plazo, con el fin de comprender cuándo la calidad del contenido se mantiene y cuándo se pierde de manera irreversible.

2. Planteamiento del problema

El crecimiento acelerado del contenido generado por modelos de inteligencia artificial (IA) plantea un desafío emergente: la posibilidad de que los modelos de nueva generación sean entrenados, de manera parcial o incluso predominante, sobre contenido previamente generado por otros modelos. Este proceso de *autoalimentación sintética* ha sido identificado como un factor crítico que puede inducir una degradación progresiva de la calidad del contenido generado, fenómeno conocido en la literatura como *model collapse* [1].

En escenarios reales, el conjunto de datos disponible en cada iteración incluye una mezcla heterogénea de:

- contenido generado por humanos (alto en información original),
- contenido generado por múltiples modelos de IA, cada uno con características, calidades e inductivas distintas,
- contenido humano modificado o transformado por usuarios,
- contenido sintético sometido a procesos de curaduría o filtrado.

Dado este contexto, surge la pregunta central:

¿Cómo evoluciona la calidad de un conjunto de entrenamiento cuando este se construye a partir de una mezcla variable de datos humanos y contenido sintético producido por múltiples modelos de IA que interactúan entre sí?

Este trabajo busca formular un modelo matemático para describir la dinámica de dicha calidad, analizar la existencia de estados estacionarios, estudiar condiciones bajo las cuales se produce autodegeneración y caracterizar el efecto de la interacción entre múltiples modelos, tomando como punto de referencia conceptual los resultados presentados en [1].

3. Supuestos del modelo

Para estudiar la dinámica de la calidad del contenido disponible para entrenamiento, consideramos los siguientes supuestos, inspirados conceptualmente en el fenómeno de *model collapse* descrito en [1], pero formulados en un marco simplificado basado en ideas de la teoría de la información de Shannon.

S1. Variable de calidad. La calidad del conjunto de entrenamiento en la iteración t se modela mediante una cantidad escalar $I_t \in [0, 1]$, interpretada como *información útil* o *información relevante* en sentido Shannoniano. Se normaliza la calidad del contenido humano a $I_{\text{hum}} = 1$.

S2. Mezcla de datos. En cada iteración, el conjunto de entrenamiento se forma mediante una mezcla de:

$$\text{datos humanos (fracción } h) \quad \text{y} \quad \text{datos sintéticos (fracción } 1 - h).$$

S3. Interacción con múltiples modelos. Existen K modelos de IA, $M_1, \dots, M_K$, cuyos contenidos combinados representan la fracción sintética total. En esta primera formulación, se modela la calidad sintética de manera agregada mediante la variable I_t . Extensiones vectoriales pueden considerarse posteriormente.

S4. Pérdida de información por realimentación. El contenido sintético derivado del conjunto de entrenamiento de la iteración previa sufre una pérdida multiplicativa de información modelada por un parámetro $\alpha \in [0, 1]$. Valores menores de 1 representan degradación por reciclaje iterativo, alineado con el fenómeno observado en [1].

S5. Filtrado o curaduría parcial. Una fracción $f \in [0, 1]$ del contenido sintético es reemplazada o corregida mediante un proceso de filtrado/curaduría, contribuyendo información equivalente a la humana.

S6. Modelo recursivo de calidad. Bajo estos supuestos, la evolución temporal de la información útil del conjunto de entrenamiento está dada por la recurrencia:

$$I_{t+1} = h + (1 - h)((1 - f)\alpha I_t + f) + \varepsilon_t,$$

donde ε_t representa ruido de muestreo de media cero.

S7. Interpretación del colapso. Decimos que ocurre *autodegeneración* o *colapso* cuando $I_t \rightarrow 0$ o cuando I_t converge a un punto fijo degenerado $I^* \ll 1$, lo que indica pérdida sostenida de información respecto a los datos humanos originales.

4. Desarrollo del modelo matemático

En esta sección desarrollamos el modelo paso a paso. Primero enumeramos y describimos los requisitos y mecanismos que conducen al *colapso* (autodegeneración) en sistemas reentrenados de forma recursiva. A continuación introducimos los conceptos básicos de la teoría de la información (Shannon) que usaremos como marco intuitivo y cuantificable. Finalmente proponemos un modelo combinado, que incorpora las ideas de *model collapse* (vistas en la bibliografía, p. ej. [1]) y la interpretación informacional (shannoniana).

4.1. Requisitos y mecanismos que favorecen el colapso

Definición 4.1 (Colapso — idea informal). Llamamos *colapso* o *autodegeneración* al fenómeno por el cual la calidad del contenido generado por modelos de IA decrece de forma sostenida a lo largo de sucesivas generaciones cuando dichos modelos se reentrenan, total o parcialmente, sobre contenido sintético generado por versiones previas.

Para que el colapso ocurra (o sea significativamente probable) se requieren, en términos heurísticos, los siguientes mecanismos y condiciones:

- C1. Realimentación recursiva:** las salidas de los modelos en una iteración sirven (en parte) como datos de entrenamiento para la siguiente iteración.
- C2. Insuficiente aporte humano:** la fracción de datos humanos nuevos por iteración es baja frente a la fracción sintética reciclada.
- C3. Pérdida acumulativa de información:** cada reuso introduce algún grado de degradación (ruido, sesgo, compresión con pérdida) que no es completamente corregido, por lo que los errores se acumulan.
- C4. Filtrado débil o inexistente:** los mecanismos de curaduría/filtrado no reemplazan suficientemente el contenido sintético de baja calidad por contenido humano o por contenido sintético de mejor calidad.
- C5. Compatibilidad entre modelos:** en un ecosistema con múltiples modelos, si existe realimentación fuerte y estructurada entre ellos (ciclos, alto grado de dependencia mutua), la degeneración puede propagarse y amplificarse.

Observación 4.1. Los experimentos y el análisis teórico en [1] demuestran cómo, en un escenario idealizado, los términos de error estadístico y la realimentación recursiva llevan a una degradación detectable. Nuestra intención es traducir esa intuición en un modelo más simple pero interpretable desde la teoría de la información.

4.2. Teoría de Shannon

Definición 4.2 (Entropía (Shannon)). Sea X una variable aleatoria con distribución P discreta. La entropía de X se define por

$$H(X) = - \sum_x P(x) \log_2 P(x),$$

medida en bits. La entropía expresa la incertidumbre promedio de X .

Definición 4.3 (Divergencia KL (intuición)). La divergencia de Kullback–Leibler entre dos distribuciones P (verdadera) y Q (aproximante) es

$$D_{\text{KL}}(P\|Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}.$$

Se interpreta como la pérdida de información (en bits) por aproximar P con Q .

Definición 4.4 (Medida de calidad informativa I). En este trabajo usaremos una medida escalar $I \in [0, 1]$ que cuantifica la *información útil* del conjunto de entrenamiento con respecto a la distribución real P . Una relación útil y operativa es

$$I \approx 1 - \kappa \cdot D_{\text{KL}}(P\|Q),$$

con $\kappa > 0$ un factor de normalización apropiado; en el caso práctico preferimos trabajar con I acotada en $[0, 1]$ y normalizada para interpretarla como proporción de información recuperable.

Observación 4.2. No necesitamos calcular D_{KL} explícitamente en nuestras simulaciones; la definición anterior solo sirve para dar interpretación: cuando Q (la distribución efectiva del dataset) se aleja de P , I decrece.

4.3. Modelo

4.3.1. Variables y parámetros

Definición 4.5 (Variables y parámetros básicos). ■ $I_t \in [0, 1]$: información útil (calidad) del conjunto de entrenamiento en iteración t .

- $h \in [0, 1]$: fracción de contenido humano nuevo en cada iteración.
- $f \in [0, 1]$: eficacia de filtrado/curaduría que reemplaza parte del sintético por contenido humano (equivalente a aporte informacional).
- $\alpha \in [0, 1]$: factor multiplicativo de degradación por realimentación recursiva (cada reuso multiplica la información por α).
- ε_t : término de ruido de muestreo (media cero), opcional para modelos estocásticos.

Proposición 4.1 (Recurrencia del modelo combinado). *Proponemos la siguiente dinámica recursiva para I_t :*

$$I_{t+1} = h + (1 - h)((1 - f)\alpha I_t + f) + \varepsilon_t \quad (1)$$

En la versión determinista (sin ruido) se tiene la forma:

$$I_{t+1} = h + (1 - h)((1 - f)\alpha I_t + f).$$

Interpretación cualitativa. La fracción h aporta directamente información humana normalizada a 1. La fracción sintética $1 - h$ se divide en dos: $(1 - f)$ que no es filtrada y aporta solo una fracción αI_t de información (degradada por reuso), y f que es curada o reemplazada por humano (aporta información equivalente a 1). El parámetro α codifica la pérdida por reentrenamiento sucesivo (ruido, compresión, sesgo acumulado). □

4.3.2. Análisis de puntos fijos y estabilidad (caso determinista)

Proposición 4.2 (Punto fijo). Si $\varepsilon_t \equiv 0$, los puntos fijos I^* satisfacen

$$I^* = h + (1 - h)((1 - f)\alpha I^* + f). \quad (2)$$

Resolviendo para I^* obtenemos

$$I^* = \frac{h + (1 - h)f}{1 - (1 - h)(1 - f)\alpha}, \quad (3)$$

siempre que el denominador sea positivo.

Demostración. Sustituimos $I_{t+1} = I_t = I^*$ en (1) (sin ruido) y despejamos:

$$I^* - (1 - h)(1 - f)\alpha I^* = h + (1 - h)f,$$

lo que da la expresión (3) tras factorizar. □

Proposición 4.3 (Condición local de estabilidad). *El sistema es localmente estable alrededor de I^* si el coeficiente*

$$\lambda := (1 - h)(1 - f)\alpha$$

cumple $|\lambda| < 1$. En ese caso las iteraciones convergen linealmente hacia I^ .*

Demostración. La función de iteración $F(I) = h + (1 - h)((1 - f)\alpha I + f)$ es afín. Su derivada es $F'(I) = (1 - h)(1 - f)\alpha$, independiente de I . La condición de estabilidad lineal es $|F'(I^*)| < 1$, que coincide con $|\lambda| < 1$. □

Observación 4.3 (Interpretación de la condición). ■ Si h grande (mucho contenido humano) o f grande (filtrado eficaz), entonces $(1-h)(1-f)$ es pequeño y es fácil que $\lambda < 1$: no hay colapso.

- Si h y f son pequeños y α está cercano a 1 (poca pérdida por reuso), λ puede acercarse a 1 o superarlo, favoreciendo degradación lenta o inestabilidad.
- En términos informacionales, λ mide la *razón neta de retención de información sintética* por iteración; cuando esta razón supera 1 la información humana no compensa la pérdida acumulada.

4.3.3. Velocidad de convergencia y tasa de degradación

Proposición 4.4 (Solución explícita (lineal) y tasa). *En el caso determinista y lineal, partiendo de I_0 , la solución cerrada es*

$$I_t = I^* + (I_0 - I^*) \lambda^t,$$

con $\lambda = (1-h)(1-f)\alpha$. Por tanto la tasa de acercamiento a I^* es exponencial con constante de tiempo $-1/\log |\lambda|$ (si $0 < |\lambda| < 1$).

Demostración. La recurrencia es afín: $I_{t+1} - I^* = \lambda(I_t - I^*)$. Iterando se obtiene la fórmula. □

Observación 4.4. Si $|\lambda| < 1$ y cercano a 1, la convergencia es lenta: degradación (si I^* es bajo) o estabilización (si I^* es alto) ocurre lentamente. Si $|\lambda| > 1$ el modelo no converge al punto fijo y puede divergir o oscilar (según extensión no lineal).

4.3.4. Extensión simple a múltiples modelos (vectorial, intuición)

Sea K el número de modelos y $\mathbf{I}_t = (I_t^{(1)}, \dots, I_t^{(K)})^\top$ el vector de informaciones útiles asociadas a cada modelo. Una formulación lineal homogénea razonable es:

$$\mathbf{I}_{t+1} = \mathbf{h} + (\mathbf{1} - \mathbf{h}) \odot \left((\mathbf{1} - \mathbf{f}) \odot (A, W \mathbf{I}_t) + \mathbf{f} \right), \quad (4)$$

donde:

- $\mathbf{h}, \mathbf{f} \in [0, 1]^K$ son vectores de fracciones humanas y filtrados por modelo;
- A es una matriz diagonal con factores α_i por modelo;
- $W \in \mathbb{R}^{K \times K}$ es la matriz de mezcla que describe qué fracción del contenido generado por el modelo j alimenta al reentrenamiento del modelo i (normalizada de forma conveniente);
- $\odot$ denota producto elemento a elemento.

Observación 4.5. En la versión lineal homogénea y sin curaduría, el Jacobiano alrededor de un punto fijo es proporcional a A, W y la condición de estabilidad implica que el radio espectral $\rho(A, W)$ debe satisfacer $(1-h)(1-f)\rho(A, W) < 1$ (en la versión homogénea con escala única). Esto enlaza con la intuición: redes W con autovalores grandes (realimentación interna fuerte) aumentan el riesgo de colapso.

4.4. Comentarios finales sobre el modelo

- El modelo (1) es simple, interpretable y captura las fuerzas básicas identificadas en [1] pero en términos informacionales accesibles.
- Permite responder las preguntas del enunciado: puntos fijos, condiciones de colapso, dependencia en h, f, α y extensión a múltiples modelos mediante W .

- Es fácilmente simulable (ver Anexo: scripts de simulación). La inclusión de ruido ε_t permite estudiar fluctuaciones y efectos estocásticos por tamaño finito de muestra.
- Para análisis más detallados (no lineales o modelos específicos de generación) conviene usar medidas más finas (Wasserstein, KL explícito) como en [1], pero la interpretación shannoniana aquí propuesta es suficiente para obtener intuiciones prácticas y condiciones de política (umbral mínimo de h , niveles de f deseables, etc.).

5. Solución e implementación

5.1. Puntos fijos y condiciones de equilibrio (caso escalar)

Buscamos q^* tal que $q_{t+1} = q_t = q^*$. Para la ecuación lineal (y $\eta_t = 0$):

$$q^* = h + (1 - h)((1 - f)\alpha q^* + f).$$

Resolver para q^* :

$$q^*(1 - (1 - h)(1 - f)\alpha) = h + (1 - h)f,$$

y por tanto (si el denominador es positivo):

$$q^* = \frac{h + (1 - h)f}{1 - (1 - h)(1 - f)\alpha}. \quad (5)$$

Condición de existencia y sentido físico: requerimos $0 \leq q^* \leq 1$ y denominador > 0 . Si el denominador tiende a 0 por parámetros muy altos, habrá divergencia; si es negativo el punto fijo no es físicamente válido (o se requiere análisis no lineal adicional).

5.2. Estabilidad (linealización)

La estabilidad local se puede estudiar derivando la función $F(q) = h + (1 - h)((1 - f)\alpha q + f)$. El criterio es $|F'(q^*)| < 1$. Aquí $F'(q) = (1 - h)(1 - f)\alpha$. Por tanto:

$$\text{estable si } |(1 - h)(1 - f)\alpha| < 1.$$

Interpretación:

- Si $(1 - h)(1 - f)\alpha < 1$, las iteraciones convergen al punto fijo q^* desde condiciones cercanas.
- Si $(1 - h)(1 - f)\alpha \geq 1$ la solución puede divergir o oscilar; en particular, cuando $(1 - h)$ (poca proporción humana), f pequeño (poco filtrado) y α cercano a 1 (fuerte realimentación), el sistema tiende a inestabilidad o colapso.

5.3. Casos no lineales y múltiples puntos fijos

Para $g(q) = q^\beta$ u otras formas no lineales, los puntos fijos satisfacen

$$q^* = h + (1 - h)((1 - f)g(q^*) + f),$$

que puede tener múltiples soluciones; su estabilidad se estudia con el Jacobiano o la derivada $F'(q^*) = (1 - h)(1 - f)g'(q^*)$.

6. Resultados y análisis (dinámica de la calidad)

6.1. Regímenes principales

De las fórmulas anteriores deducimos intuiciones:

- **Región estable (no colapso):** cuando $(1 - h)(1 - f)\alpha < 1$. La calidad converge a un valor no trivial q^* (ver (5)).
- **Régimen de colapso:** si $(1 - h)(1 - f)\alpha$ es cercano o mayor a 1, especialmente con h pequeño y f pequeño, la calidad puede disminuir progresivamente hasta un valor bajo (colapso). En el límite extremo $h = 0, f = 0, \alpha < 1$ se tiene $q_{t+1} = \alpha q_t$ y entonces $q_t \rightarrow 0$ si $\alpha < 1$.
- **Velocidad de degradación:** la razón de decrecimiento (tasa efectiva) es aproximadamente $(1 - h)(1 - f)\alpha$ en el régimen lineal. Si ésta es cercana a 1 la degradación es lenta; si es mucho menor que 1 la convergencia es rápida.

6.2. Efecto de múltiples modelos

En el modelo vectorial, la estabilidad local se obtiene por el análisis del Jacobiano matricial en el punto fijo $\mathbf{q}^*$:

$$J = \left. \frac{\partial \mathbf{F}}{\partial \mathbf{q}} \right|_{\mathbf{q}^*}$$

y la condición de estabilidad es que todos los autovalores $\lambda_i(J)$ satisfacen $|\lambda_i| < 1$.

En el caso lineal $g(q) = \alpha q$ y parámetros homogéneos ($h_i = h, f_i = f$),

$$\mathbf{q}_{t+1} = h \mathbf{1} + (1 - h)((1 - f)\alpha W \mathbf{q}_t + f \mathbf{1}),$$

y entonces $J = (1 - h)(1 - f)\alpha W$. Por tanto la condición de estabilidad es

$$(1 - h)(1 - f)\alpha \cdot \rho(W) < 1,$$

donde $\rho(W)$ es el radio espectral (mayor valor absoluto de autovalores) de W .

Interpretación:

- Si la red de mezcla W es fuertemente conectada y favorece realimentación interna (alto $\rho(W)$), el riesgo de colapso aumenta.
- Diversidad en W que reduce $\rho(W)$ (por ejemplo mezcla equilibrada entre modelos) puede ayudar a mantener estabilidad.

7. Discusión

- La presencia de una fracción mínima h de contenido humano es crucial: existe un umbral por debajo del cual la realimentación sintética domina y puede producir colapso.
- El filtrado (curaduría) con eficacia f atenúa el efecto adverso de reciclar contenido. Estrategias que incrementen f (p. ej. verificación humana, detectores de contenido sintético) son efectivas.
- La diversidad entre modelos (heterogeneidad en $Q^{(i)}$ y en la matriz W) puede ser un arma de doble filo: puede introducir resiliencia si la mezcla evita dependencias cíclicas; pero si modelos se retroalimentan fuertemente entre sí, la degeneración puede acelerarse.

- Comparación con Shumailov et al.: el paper muestra colapso en escenarios ideales. Nuestro modelo reproduce esta conducta y aporta intuiciones sobre el rol de h, f, α y la estructura W .

8. Resultados numéricos y visualización de la dinámica

En esta sección implementamos y simulamos el modelo dinámico con parámetros dependientes del tiempo h_t, f_t, α_t descrito previamente. Nuestro objetivo es observar, de forma cuantitativa, en qué condiciones la calidad I_t se mantiene en niveles aceptables y en qué condiciones vemos fenómenos de autodegeneración compatibles con el *model collapse*.

Generamos cinco gráficas principales que referimos en el texto como Figuras 1–5. Cada figura ilustra el comportamiento de la dinámica bajo un tipo de variación de parámetros:

- Figura 1 : trayectoria base de I_t junto con h_t, f_t, α_t .
- Figura 2 : efecto de la velocidad de caída de la fracción humana γ .
- Figura 3 : efecto de la velocidad de aumento de la curaduría δ .
- Figura 4 : diagrama de fase en el plano (γ, δ) usando la calidad promedio final.
- Figura 5 : efecto de la degradación adaptativa controlada por α_1 .

En todos los experimentos trabajamos con valores de referencia

$$I_0 = 1,0, \quad h_0 = 0,2, \quad f_{\text{máx}} = 0,4, \quad \alpha_0 = 0,9,$$

y variamos únicamente los parámetros indicados en cada experimento. De esta forma interpretamos las gráficas como cortes de un mismo modelo dinámico. El código completo de las simulaciones lo incluimos en el anexo de código Python para simulaciones.

8.1. Trayectoria base y evolución de h_t, f_t, α_t (Figura 1)

En la Figura 1 representamos una trayectoria base del sistema para un horizonte temporal de $T = 300$ iteraciones, con parámetros

$$\gamma = 0,01, \quad \delta = 0,03, \quad \alpha_1 = 0,1,$$

y ruido nulo $\varepsilon_t \equiv 0$. En la misma gráfica mostramos simultáneamente la calidad I_t y las curvas h_t, f_t, α_t .

Observamos tres fases bien definidas:

- En la fase inicial, vemos que I_t desciende desde $I_0 = 1$ hasta un mínimo intermedio. En esta zona todavía contamos con una fracción apreciable de datos humanos h_t , pero la curaduría f_t es baja y la realimentación sintética (controlada por α_t) empieza a introducir pérdida acumulativa de información.
- En una segunda fase, f_t crece y se aproxima a $f_{\text{máx}}$, mientras que h_t ya es muy pequeño. Vemos que I_t se recupera parcialmente y sube hacia un valor intermedio alto. La curaduría compensa parte de la degradación y actúa como una fuente indirecta de información “tipo humana”.
- Finalmente, entramos en una fase casi estacionaria donde I_t se estabiliza alrededor de ese valor intermedio alto, con variaciones pequeñas. Interpretamos este régimen como un punto fijo efectivo del sistema dinámico con parámetros ya casi constantes.

Dinámica de la calidad (escenario_base)

Iteración t	Calidad I_t	h_t	f_t	α_t
0	1.00	0.25	0.00	1.00
50	0.88	0.18	0.35	1.00
100	0.89	0.12	0.42	1.00
150	0.89	0.09	0.45	1.00
200	0.89	0.07	0.45	1.00
250	0.89	0.06	0.45	1.00
300	0.89	0.05	0.45	1.00

8.2. Efecto de la caída de h_t variación de γ (Figura 2)

Vemos que, para tiempos pequeños, todas las curvas coinciden o son muy similares, ya que $h_t \approx h_0$ y el sistema aún dispone de una cantidad apreciable de datos humanos. A medida que avanzan las iteraciones:

- 11




Figura 2: Comparación de trayectorias de I_t para distintos valores de γ .

8.3. Efecto de la mejora de la curaduría: variación de δ (Figura 3)

En la Figura 3 analizamos el impacto de la velocidad de aumento de la curaduría δ , manteniendo γ y los demás parámetros fijos. Consideramos valores $\delta \in \{0, 0, 0, 01, 0, 03, 0, 05\}$.

Los resultados indican que:

- Cuando $\delta = 0$, el filtrado prácticamente no mejora con el tiempo ($f_t \approx 0$). En este caso, la calidad I_t desciende y se estabiliza en un nivel bajo, dominado por la realimentación sintética, lo que es coherente con un régimen cercano al colapso.
- A medida que incrementamos δ , el filtrado entra en juego más temprano y alcanza valores altos antes de que la fracción humana h_t se vuelva despreciable. Observamos que las trayectorias de I_t recuperan parte de la calidad perdida y convergen a valores finales mayores.
- Para δ suficientemente grande, la curaduría compensa de forma más agresiva los efectos de la realimentación y el sistema se estabiliza en un nivel de calidad similar al de la trayectoria base o incluso algo superior.

Con este experimento confirmamos que la curaduría no solo debe existir, sino activarse con suficiente rapidez para evitar que el sistema pase muchas iteraciones en un régimen altamente degenerado.




Figura 3: Comparación de trayectorias de I_t para distintos valores de δ .

8.4. Diagrama de fase en el plano (γ, δ) (Figura 4)

Para sintetizar la interacción entre la velocidad de agotamiento de datos humanos (γ) y la velocidad de mejora de la curaduría (δ), construimos un diagrama de fase en el plano (γ, δ) . En la Figura 4 representamos, para cada par (γ, δ) en una rejilla, la calidad promedio de las últimas iteraciones,

$$\bar{I} = \frac{1}{20} \sum_{t=T-19}^T I_t,$$

con $T = 400$.

Observamos dos regiones cualitativamente distintas:

- Una región de *alta calidad*, localizada aproximadamente en la zona de γ pequeño y δ moderado o grande. En esta zona el aporte humano se mantiene por suficiente tiempo y el filtrado alcanza rápidamente buenos niveles; la dinámica de I_t se parece al caso estacionario estable.
- Una región de *baja calidad*, asociada a combinaciones de γ grandes (agotamiento rápido de datos humanos) y δ pequeños (curaduría lenta). Aquí el sistema pasa muchas iteraciones en un régimen dominado por contenido sintético poco filtrado y la calidad colapsa hacia valores bajos.

La frontera entre ambas regiones sugiere la existencia de umbrales de política: si permitimos que γ supere cierto valor sin acompañarlo de un aumento suficiente en δ , el sistema entra en un régimen de autodegeneración difícil de revertir.




Figura 5: Comparación de trayectorias de I_t para distintos valores de α_1 .

9. Extensión empírica: preservación de información en cruces de modelos de lenguaje

Hasta este punto, el factor de degradación α ha sido un *parámetro libre* de la simulación. En esta sección damos un paso adicional: medimos α de forma *empírica* sobre modelos de lenguaje reales y, en lugar de estudiar el lazo recursivo de un modelo sobre sí mismo ($A \rightarrow A$), estudiamos los *cruces* entre modelos distintos ($A \rightarrow B$): el modelo A genera contenido y el modelo B lo procesa. Como veremos, esta relación es inherentemente *no conmutativa*: en general $\alpha_{A \rightarrow B} \neq \alpha_{B \rightarrow A}$, lo que enlaza de forma natural con la matriz de mezcla W de la formulación vectorial (4).

9.1. Modelos y corpus de referencia humano

Empleamos cuatro modelos de lenguaje autorregresivos de código abierto, de tamaños y familias distintas, lo que garantiza heterogeneidad en sus distribuciones:

Etiqueta	Identificador (HuggingFace)	Parámetros
pythia70m	EleutherAI/pythia-70m	~ 70 M
distilgpt2	distilgpt2	~ 82 M
smollm2	HuggingFaceTB/SmolLM2-135M	~ 135 M
qwen0.5b	Qwen/Qwen2.5-0.5B	~ 500 M

Cuadro 1: Modelos de lenguaje empleados en el experimento de cruces. Usamos las versiones base, pues nos interesa la distribución de lenguaje cruda de cada modelo.

Como referencia de *texto humano genuino* usamos el dataset SQUAD [2], cuyos campos **context** son párrafos de Wikipedia escritos por humanos. Este corpus cumple un doble papel en nuestro experimento:

- sus fragmentos iniciales sirven como *semillas* de generación comunes para todos los modelos, de modo que ninguno parte con ventaja temática;
- el texto completo actúa como la *referencia humana* del supuesto **S1**, materializando empíricamente la normalización $I_{\text{hum}} = 1$.

9.2. Medida empírica de información: cross-entropy

La conexión con el marco shannoniano de la Sección 4.2 es directa.

Definición 9.1 (Cross-entropy por token). Dado un texto $x = (x_1, \dots, x_N)$ y un modelo de lenguaje M con distribución condicional $P_M(\cdot | x_{<i})$, la *cross-entropy media por token* que M asigna a x es

$$H_M(x) = -\frac{1}{N} \sum_{i=1}^N \log P_M(x_i | x_{<i}), \quad (6)$$

medida en nats por token. Expresa el costo promedio de descripción de x bajo el modelo M .

Observación 9.1. Esta cantidad es el análogo empírico de las Definiciones 4.2 y 4.3: si M encuentra el texto muy sorprendente (alta perplejidad), su distribución está lejos de la que generó x , lo que en el lenguaje de la Definición 4.4 equivale a una divergencia D_{KL} mayor y, por tanto, a una pérdida de información útil.

Proposición 9.1 (Factor de degradación empírico del cruce $A \rightarrow B$). Sea x_A un corpus generado por el modelo A . Proponemos medir la degradación del cruce $A \rightarrow B$ mediante

$$\alpha_{A \rightarrow B} = \frac{H_A(x_A)}{H_B(x_A)} \quad (7)$$

donde $H_A(x_A)$ es la auto-entropía de A (el costo de describir su propio texto) y $H_B(x_A)$ es el costo que el modelo B paga por describir ese mismo texto.

Interpretación cualitativa. El cociente (7) separa dos efectos que de otro modo se confundirían: qué tan predecible es el texto de A en sí mismo, y cuánta información pierde B al procesarlo. Sin la normalización por $H_A(x_A)$, un modelo que generara texto muy repetitivo (entropía absoluta baja) aparentaría preservar mucha información, cuando en realidad produce poca información que preservar. Cuando B describe el texto de A casi tan bien como el propio A , el cociente se acerca a 1 (poca pérdida); cuando B encuentra ese texto muy sorprendente, el cociente cae (pérdida fuerte), en analogía directa con el papel de α en el supuesto **S4**. $\square$

Observación 9.2 (No conmutatividad). La medida (7) es asimétrica por construcción: $\alpha_{A \rightarrow B}$ se calcula sobre el texto de A , mientras que $\alpha_{B \rightarrow A}$ se calcula sobre el texto de B , que proviene de una distribución distinta. Esta asimetría es exactamente la estructura que la matriz de mezcla W de la ecuación (4) permite codificar.

Para la fila correspondiente al corpus humano, que no posee un “modelo generador” propio, tomamos como referencia $H_{\text{ref}}(\text{hum}) = \min_j H_j(x_{\text{hum}})$: el modelo que mejor describe el texto humano fija la cota inferior empírica de su costo de descripción. Esto produce los factores $\alpha_{\text{hum} \rightarrow j}$, que responden la pregunta más fiel al marco del trabajo: *¿cuánta información del contenido humano preserva cada modelo?*

9.3. Protocolo experimental

El experimento procede en tres pasos:

- P1. Generación.** Cada modelo M_i genera un corpus x_i de continuaciones a partir de las mismas semillas extraídas de SQUAD (muestreo con temperatura 1,0 y *nucleus sampling* $p = 0,95$).
- P2. Evaluación cruzada.** Para cada par ordenado (generador i , evaluador j) calculamos $H_j(x_i)$ según (6), incluyendo la fila humana, lo que produce una matriz rectangular de cross-entropies y, vía (7), la matriz de degradación $\alpha_{i \rightarrow j}$.
- P3. Inyección en la dinámica.** Sustituimos cada $\alpha_{i \rightarrow j}$ medido en la recurrencia (1) con $h = 0,05$ y $f = 0$ (sin curaduría, para aislar el efecto del cruce), y obtenemos tanto la trayectoria I_t como la calidad estacionaria $I_{i \rightarrow j}^*$ mediante la fórmula cerrada (3).

9.4. Resultados del experimento de cruces

La matriz de degradación medida la reportamos en el Cuadro 2 y la visualizamos, junto con la matriz de calidades estacionarias $I_{i \rightarrow j}^*$, en la Figura 6. La Figura 7 muestra la dinámica I_t de todos los cruces simultáneamente, la Figura 8 la desagrega por generador, y la Figura 9 resume el ranking de preservación.

Generador i	Evaluador j			
	pythia70m	distilgpt2	smollm2	qwen0.5b
pythia70m	1.000	0.837	0.918	0.835
distilgpt2	0.965	1.000	1.145	1.033
smollm2	0.707	0.725	1.000	0.823
qwen0.5b	0.596	0.651	0.798	1.000
humano	0.619	0.700	0.802	1.000

Cuadro 2: Matriz de degradación empírica $\alpha_{i \rightarrow j}$ medida según (7). La asimetría media fuera de la diagonal es 0,234 y la máxima 0,420 (par `distilgpt2`↔`smollm2`: 1,145 frente a 0,725), lo que confirma cuantitativamente la no conmutatividad de los cruces.

Del análisis de estos resultados destacamos las siguientes observaciones:

- **Preservación del contenido humano.** La fila *humano* del Cuadro 2 ordena a los modelos según su fidelidad informacional al texto de SQUAD, el criterio más relevante bajo el supuesto **S1**. Vemos que el ranking resulta perfectamente monótono en la capacidad del modelo:

$$\alpha_{\text{hum} \rightarrow \text{qwen0.5b}} = 1,000 > \alpha_{\text{hum} \rightarrow \text{smollm2}} = 0,802 > \alpha_{\text{hum} \rightarrow \text{distilgpt2}} = 0,700 > \alpha_{\text{hum} \rightarrow \text{pythia70m}} = 0,619.$$

El modelo de mayor capacidad alcanza la cota de referencia (es, de hecho, el mínimo que ancla la normalización de la fila humana, con $H = 2,088$ nats/token sobre el corpus de SQUAD), mientras que el más pequeño pierde cerca del 38 % de la información humana en una sola pasada.

- **Jerarquía de capacidad y asimetría.** Observamos que los modelos de mayor capacidad son los mejores *evaluadores* (α entrante medio: `qwen0.5b` 0,923, `smollm2` 0,916, frente a aproximadamente 0,72 de los dos menores), pero su texto es el que *peor sobrevive* al ser procesado por los demás (α saliente medio de `qwen0.5b`: 0,682, el menor de los cuatro). El cruce más degradante de todo el experimento es `qwen0.5b` → `pythia70m` con $\alpha = 0,596$ e $I^* = 0,115$: el modelo pequeño encuentra muy sorprendente el texto del grande. Esto reproduce empíricamente la condición de compatibilidad **C5** de la Sección 4.1.

- **Consecuencia dinámica.** Diferencias moderadas en α se amplifican en el estacionario: con $f = 0$ y $h = 0,05$ se tiene $I^* = h/(1 - (1 - h)\alpha)$, expresión no lineal y muy sensible cerca de $\alpha \rightarrow 1$. Así, el cruce $\text{hum} \rightarrow \text{smollm2}$ ($\alpha = 0,802$) se estabiliza en $I^* = 0,210$, mientras que $\text{hum} \rightarrow \text{pythia70m}$ ($\alpha = 0,619$) cae hasta $I^* = 0,122$: una brecha de 0,18 en α casi duplica la meseta de calidad.
- **Cruces supraunitarios.** Dos cruces superan la unidad: $\text{distilgpt2} \rightarrow \text{smollm2}$ ($\alpha = 1,145$) y $\text{distilgpt2} \rightarrow \text{qwen0.5b}$ ($\alpha = 1,033$). Discutimos este fenómeno en la Observación 9.3.

Observación 9.3 (Cruces con $\alpha > 1$). Que un cruce supere la unidad significa que el evaluador describe el texto del generador con *menor* costo que el propio generador: **smollm2** y **qwen0.5b** asignan al texto de **distilgpt2** cross-entropías de 2,691 y 2,983 nats/token, por debajo de la auto-entropía de **distilgpt2** (3,081). La lectura es que **distilgpt2** genera texto lo bastante genérico como para que modelos más capaces lo compriman mejor que su autor; en estos cruces no hay pérdida de información en el sentido de (7). Para la inyección en la dinámica truncamos estos valores a $\alpha = 1$: de lo contrario el coeficiente $\lambda = (1 - h)\alpha$ supera 1 y el punto fijo (3) deja de ser físicamente válido (denominador negativo), en consistencia con la condición de existencia discutida en la Sección 5.1. Con el truncamiento, dichos cruces se interpretan como *preservación perfecta*: $I^* = 1$.




Figura 6: Matrices empíricas de degradación $\alpha_{i \rightarrow j}$ (izquierda) y de calidad estacionaria $I_{i \rightarrow j}^*$ (derecha). Filas: generador (incluida la referencia humana); columnas: evaluador. La asimetría respecto a la diagonal evidencia la no conmutatividad de los cruces.




Figura 7: Dinámica de la calidad I_t para todos los cruces $i \rightarrow j$, obtenida al inyectar cada $\alpha_{i \rightarrow j}$ medido en la recurrencia (1) con $h = 0,05$ y $f = 0$. En trazo grueso, los cruces con origen en el corpus humano.




Figura 8: Trayectorias I_t desagregadas por generador: cada panel muestra cómo sobrevive el texto de un mismo origen (incluido el corpus humano) según qué modelo lo procese.




Figura 9: Ranking de preservación de información: α entrante medio por evaluador (izquierda) y α saliente medio por generador (derecha).

9.5. Acoplamiento vectorial con la matriz empírica

Finalmente, cerramos el círculo con la formulación vectorial de la Sección 4.3.4: el bloque modelo–modelo de la matriz α medida, normalizado por filas, lo empleamos como matriz de mezcla W empírica en la dinámica acoplada

$$\mathbf{I}_{t+1} = h \mathbf{1} + (1 - h)((1 - f) W \mathbf{I}_t + f \mathbf{1}),$$

y verificamos la condición de estabilidad $(1 - h)(1 - f) \rho(W) < 1$ con el radio espectral de la matriz medida. Al ser W estocástica por filas, $\rho(W) = 1$ y la estabilidad queda gobernada por el margen $(1 - h)(1 - f) < 1$ (con $h = 0,05$ y $f = 0$, el coeficiente vale 0,95): exactamente la conclusión de política de la Sección 7, ahora sustentada en mediciones sobre modelos reales (Figura 10).




Figura 10: Dinámica vectorial acoplada usando como matriz de mezcla W la matriz de cruces medida empíricamente entre los cuatro modelos.

9.6. Alcance y limitaciones

- Los valores absolutos de $\alpha_{i \rightarrow j}$ dependen del conjunto de semillas, la temperatura de muestreo y la longitud de generación; lo robusto del experimento es el *orden relativo* de los cruces y

la estructura asimétrica de la matriz.

- Un estudio con vocación de generalidad requeriría promediar sobre múltiples semillas aleatorias y un corpus de referencia mayor.
- La normalización de la fila humana mediante el mínimo $\min_j H_j(x_{\text{hum}})$ es una convención razonable pero no única; una alternativa es construir un modelo de referencia explícito (por ejemplo, un modelo de n-gramas ajustado sobre el corpus humano) que provea la auto-entropía faltante.

10. Conclusiones

1. Presentamos un modelo sencillo y interpretable que captura los factores claves de autodegeneración: realimentación, fracción humana y filtrado.
2. Derivamos condiciones de estabilidad explícitas (ej. $(1-h)(1-f)\alpha < 1$) que separan regímenes de mantenimiento de calidad y colapso.
3. En escenarios multi-modelo, el radio espectral de la matriz de mezcla W es un parámetro crítico.
4. Políticas prácticas recomendadas: mantener una fracción mínima de contenido humano h , aumentar la eficacia de curaduría f , y diseñar arquitecturas y políticas de mezcla W que reduzcan la realimentación circular.
5. Concluimos, por tanto, que el modelo dinámico con h_t, f_t, α_t nos permite describir escenarios más realistas y nos ofrece una guía cuantitativa para diseñar políticas de entrenamiento: debemos sostener una inyección mínima de datos humanos, invertir en curaduría temprana y evitar políticas que refuercen la degradación cuando la calidad ya es baja.

Bibliografía

Referencias

- [1] I. Shumailov, Z. Shumaylov, Y. Zhao, et al., *AI models collapse when trained on recursively generated data*.
- [2] P. Rajpurkar, J. Zhang, K. Lopyrev, P. Liang, *SQuAD: 100,000+ Questions for Machine Comprehension of Text*, Proceedings of EMNLP, 2016.
- [3] Qwen Team, *Qwen2.5: A Party of Foundation Models*, 2024.

A. Anexo: código Python para simulaciones

```
import numpy as np
import matplotlib.pyplot as plt

def simulate_scalar(alpha=0.9, h=0.1, f=0.0, q0=1.0, T=200):
    q = np.zeros(T+1)
    q[0] = q0
    for t in range(T):
        q[t+1] = h + (1-h)*((1-f)*alpha*q[t] + f)
    return q
```

```
# ejemplo
if __name__ == "__main__":
    alpha = 0.95
    h = 0.05
    f = 0.0
    q0 = 1.0
    T = 200
    q = simulate_scalar(alpha, h, f, q0, T)
    plt.plot(q, label=f'alpha={alpha}, h={h}, f={f}')
    plt.ylim(0,1.05)
    plt.xlabel('Iteración t')
    plt.ylabel('Calidad q_t')
    plt.legend()
    plt.grid(True)
    plt.show()
```

B. Anexo: sugerencias de experimentos numéricos

- Barrido en $h \in [0, 0.5]$ para distintos α y f y medir q_T en el tiempo largo T .
- Modelo vectorial con K y matrices W tipo circulante, aleatorias o con comunidad, y medir el radio espectral $\rho(W)$.
- Introducir ruido estocástico η_t con varianza inversamente proporcional a M para estudiar fluctuaciones.

C. Anexo: código Python para simulaciones dinámicas

En este anexo presentamos el script de Python que usamos para generar las Figuras 1–5 (1.png–5.png) y los archivos de datos `trayectoria_base.csv`, `gamma_0p0.csv`, `gamma_0p005.csv`, `gamma_0p01.csv`, `gamma_0p02.csv`, `delta_values.csv`, `delta_0p0.csv`, `delta_0p01.csv`, `delta_0p03.csv`, `delta_0p05.csv`, `I_final_matrix.csv`, `alpha1_0p0.csv`, `alpha1_0p05.csv`, `alpha1_0p1.csv` y `alpha1_0p2.csv`. Con este código reproducimos tanto las gráficas como los datos numéricos que analizamos en la Sección de resultados.

```
import numpy as np
import matplotlib.pyplot as plt

# =====
# Modelo dinámico de autodegeneración con h_t, f_t, alpha_t
# =====

def schedule_h(t, h0=0.2, gamma=0.01):
    """
    Fracción de datos humanos en la iteración t:
        h_t = h0 * exp(-gamma * t)
    """
    return h0 * np.exp(-gamma * t)

def schedule_f(t, f_max=0.4, delta=0.03):
```

```

"""
Eficacia de filtrado/curaduría en la iteración t:
    f_t = f_max * (1 - exp(-delta * t))
"""
return f_max * (1.0 - np.exp(-delta * t))

def alpha_adaptive(I_t, alpha0=0.9, alpha1=0.1):
    """
    Factor de degradación adaptativo:
        alpha_t = alpha0 + alpha1 * (1 - I_t)
    Se recorta al intervalo [0, 1] por seguridad numérica.
    """
    alpha_t = alpha0 + alpha1 * (1.0 - I_t)
    return np.clip(alpha_t, 0.0, 1.0)

def simulate_dynamic(
    T=200,
    I0=1.0,
    h0=0.2,
    f_max=0.4,
    gamma=0.01,
    delta=0.03,
    alpha0=0.9,
    alpha1=0.1,
    noise_std=0.0,
    random_state=None,
):
    """
    Simulamos la dinámica:

        
$$I_{t+1} = h_t + (1 - h_t) * ((1 - f_t) * \alpha_t * I_t + f_t) + \epsilon_t$$


    donde:
        h_t      = schedule_h(t, h0, gamma)
        f_t      = schedule_f(t, f_max, delta)
        alpha_t  = alpha_adaptive(I_t, alpha0, alpha1)

    Devolvemos:
        t      : arreglo de tiempos [0, 1, ..., T]
        I      : calidad en cada iteración
        h_seq  : valores de h_t
        f_seq  : valores de f_t
        a_seq  : valores de alpha_t
    """
    if random_state is not None:
        np.random.seed(random_state)

    t = np.arange(T + 1)
    I = np.zeros(T + 1)

```

```

h_seq = np.zeros(T + 1)
f_seq = np.zeros(T + 1)
a_seq = np.zeros(T + 1)

I[0] = I0

for k in range(T):
    h_t = schedule_h(k, h0=h0, gamma=gamma)
    f_t = schedule_f(k, f_max=f_max, delta=delta)
    a_t = alpha_adaptive(I[k], alpha0=alpha0, alpha1=alpha1)

    if noise_std > 0:
        eps_t = np.random.normal(0.0, noise_std)
    else:
        eps_t = 0.0

    I_next = h_t + (1.0 - h_t) * ((1.0 - f_t) * a_t * I[k] + f_t) + eps_t

    # Forzamos a estar en [0, 1]
    I[k + 1] = np.clip(I_next, 0.0, 1.0)

    h_seq[k] = h_t
    f_seq[k] = f_t
    a_seq[k] = a_t

# Rellenamos último punto de las secuencias
h_seq[-1] = h_seq[-2]
f_seq[-1] = f_seq[-2]
a_seq[-1] = a_seq[-2]

return t, I, h_seq, f_seq, a_seq

# =====
# Funciones auxiliares de visualización
# y guardado de datos
# =====

def plot_time_series(t, I, h_seq, f_seq, a_seq, filename_png):
    """
    Graficamos en una misma figura:
        - evolución de I_t
        - evolución de h_t, f_t, alpha_t (segundo eje)
    y guardamos la figura en filename_png.
    """
    fig, ax1 = plt.subplots()
    ax1.plot(t, I, label="Calidad $I_t$")
    ax1.set_xlabel("Iteración $t$")
    ax1.set_ylabel("Calidad $I_t$")
    ax1.set_ylim(0, 1.05)

```



```

ax2 = ax1.twinx()
ax2.plot(t, h_seq, linestyle="--", label="$h_t$")
ax2.plot(t, f_seq, linestyle="-.", label="$f_t$")
ax2.plot(t, a_seq, linestyle=":", label="$\\alpha_t$")
ax2.set_ylabel("Parámetros dinámicos")

# Leyenda combinada
lines_1, labels_1 = ax1.get_legend_handles_labels()
lines_2, labels_2 = ax2.get_legend_handles_labels()
ax1.legend(lines_1 + lines_2, labels_1 + labels_2, loc="best")

fig.suptitle("Dinámica de la calidad (trayectoria base)")
fig.tight_layout()
plt.grid(True)
plt.savefig(filename_png, dpi=300, bbox_inches="tight")
plt.close(fig)

def save_trajectory_to_csv(filename_csv, t, I):
    """
    Guardamos en un CSV las columnas:
        t, I_t
    """
    data = np.column_stack([t, I])
    np.savetxt(
        filename_csv,
        data,
        delimiter=",",
        header="t,I",
        comments=""
    )

def label_from_float(x):
    """
    Convertimos, por ejemplo:
        0.0    -> "0p0"
        0.005  -> "0p005"
        0.01   -> "0p01"
        0.02   -> "0p02"
    para usar en nombres de archivo.
    """
    return str(x).replace(".", "p")

# =====
# Experimentos numéricos
# =====

def run_base_trajectory():
    """

```

```

Generamos la trayectoria base (Figura 1 y trayectoria_base.csv).
"""
t, I, h_seq, f_seq, a_seq = simulate_dynamic(
    T=300,
    I0=1.0,
    h0=0.2,
    f_max=0.4,
    gamma=0.01,
    delta=0.03,
    alpha0=0.9,
    alpha1=0.1,
    noise_std=0.0,
    random_state=42,
)

# Guardamos figura y datos
plot_time_series(t, I, h_seq, f_seq, a_seq, filename_png="1.png")
save_trajectory_to_csv("trayectoria_base.csv", t, I)

def run_compare_gamma():
    """
    Comparamos distintos valores de gamma y generamos:
    - Figura 2 (2.png)
    - Archivos gamma_0p0.csv, gamma_0p005.csv, gamma_0p01.csv, gamma_0p02.csv
    """
    gammas = [0.0, 0.005, 0.01, 0.02]
    T = 300
    t = np.arange(T + 1)

    plt.figure()
    for gamma in gammas:
        _, I, _, _, _ = simulate_dynamic(
            T=T,
            I0=1.0,
            h0=0.2,
            f_max=0.4,
            gamma=gamma,
            delta=0.03,
            alpha0=0.9,
            alpha1=0.1,
            noise_std=0.0,
        )
        label = label_from_float(gamma)
        # Guardamos cada trayectoria en un CSV
        save_trajectory_to_csv(f"gamma_{label}.csv", t, I)
        # Graficamos
        plt.plot(t, I, label=f"$\\gamma = {gamma}$")

    plt.xlabel("Iteración $t$")
    plt.ylabel("Calidad $I_t$")

```

```

plt.ylim(0, 1.05)
plt.title("Efecto de la velocidad de caída de  $h_t$  (parámetro  $\gamma$ )")
plt.legend()
plt.grid(True)
plt.savefig("2.png", dpi=300, bbox_inches="tight")
plt.close()

def run_compare_delta():
    """
    Comparamos distintos valores de delta y generamos:
    - Figura 3 (3.png)
    - Archivos delta_values.csv y delta_*.csv
    """
    deltas = [0.0, 0.01, 0.03, 0.05]
    T = 300
    t = np.arange(T + 1)

    # Guardamos los valores de delta usados
    np.savetxt(
        "delta_values.csv",
        np.array(deltas),
        delimiter=",",
        header="delta",
        comments=""
    )

    plt.figure()
    for delta in deltas:
        _, I, _, _, _ = simulate_dynamic(
            T=T,
            I0=1.0,
            h0=0.2,
            f_max=0.4,
            gamma=0.01,
            delta=delta,
            alpha0=0.9,
            alpha1=0.1,
            noise_std=0.0,
            random_state=42,
        )
        label = label_from_float(delta)
        save_trajectory_to_csv(f"delta_{label}.csv", t, I)
        plt.plot(t, I, label=f" $\gamma = \{delta\}$ ")

    plt.xlabel("Iteración  $t$ ")
    plt.ylabel("Calidad  $I_t$ ")
    plt.ylim(0, 1.05)
    plt.title("Efecto de la velocidad de aumento de  $f_t$  (parámetro  $\delta$ )")
    plt.legend()
    plt.grid(True)

```

```

plt.savefig("3.png", dpi=300, bbox_inches="tight")
plt.close()

def run_phase_diagram_gamma_delta():
    """
    Construimos el diagrama de fase en el plano (gamma, delta) y
    guardamos:
        - Figura 4 (4.png)
        - Matriz I_final_matrix.csv con los promedios finales.
    """
    gamma_values = np.linspace(0.0, 0.04, 9)    # 9 valores de gamma
    delta_values = np.linspace(0.0, 0.06, 13)   # 13 valores de delta

    G = len(gamma_values)
    D = len(delta_values)
    I_final = np.zeros((G, D))

    T = 400

    for i, gamma in enumerate(gamma_values):
        for j, delta in enumerate(delta_values):
            _, I, _, _, _ = simulate_dynamic(
                T=T,
                I0=1.0,
                h0=0.2,
                f_max=0.4,
                gamma=gamma,
                delta=delta,
                alpha0=0.9,
                alpha1=0.1,
                noise_std=0.0,
                random_state=42,
            )
            # Promedio de las últimas 20 iteraciones
            I_final[i, j] = np.mean(I[-20:])

    # Guardamos la matriz de promedios finales
    np.savetxt("I_final_matrix.csv", I_final, delimiter=",")

    plt.figure()
    im = plt.imshow(
        I_final,
        origin="lower",
        aspect="auto",
        extent=[
            delta_values[0],
            delta_values[-1],
            gamma_values[0],
            gamma_values[-1],
        ],
    ),

```

```

)
plt.colorbar(im, label="Calidad promedio final  $\bar{I}$ ")
plt.xlabel(" $\Delta$  (ritmo de aumento de  $f_t$ )")
plt.ylabel(" $\gamma$  (ritmo de caída de  $h_t$ )")
plt.title("Diagrama de fase en el plano  $(\gamma, \Delta)$ ")
plt.savefig("4.png", dpi=300, bbox_inches="tight")
plt.close()

def run_compare_alpha_adaptive():
    """
    Comparamos distintos valores de alpha1 (degradación adaptativa) y
    generamos:
        - Figura 5 (5.png)
        - Archivos alpha1_0p0.csv, alpha1_0p05.csv, alpha1_0p1.csv, alpha1_0p2.csv
    """
    alpha1_values = [0.0, 0.05, 0.1, 0.2]
    T = 300
    t = np.arange(T + 1)

    plt.figure()
    for alpha1 in alpha1_values:
        _, I, _, _, _ = simulate_dynamic(
            T=T,
            I0=1.0,
            h0=0.2,
            f_max=0.4,
            gamma=0.01,
            delta=0.03,
            alpha0=0.9,
            alpha1=alpha1,
            noise_std=0.0,
            random_state=42,
        )
        label = label_from_float(alpha1)
        save_trajectory_to_csv(f"alpha1_{label}.csv", t, I)
        plt.plot(t, I, label=f" $\alpha_1 = {alpha1}$ ")

    plt.xlabel("Iteración  $t$ ")
    plt.ylabel("Calidad  $I_t$ ")
    plt.ylim(0, 1.05)
    plt.title("Efecto de la degradación adaptativa (parámetro  $\alpha_1$ )")
    plt.legend()
    plt.grid(True)
    plt.savefig("5.png", dpi=300, bbox_inches="tight")
    plt.close()

# =====
# Punto de entrada principal
# =====

```

```
if __name__ == "__main__":  
    # Trayectoria base (Figura 1)  
    run_base_trajectory()  
  
    # Comparación de gammas (Figura 2)  
    run_compare_gamma()  
  
    # Comparación de deltas (Figura 3)  
    run_compare_delta()  
  
    # Diagrama de fase (Figura 4)  
    run_phase_diagram_gamma_delta()  
  
    # Comparación de  $\alpha_1$  (Figura 5)  
    run_compare_alpha_adaptive()
```